UNIVERSIDAD DEL BÍO-BÍO
Facultad de Ciencias
Departamento de Estadística

# EVALUACIÓN N.º 1

# ¿Cuánto vende realmente una tienda en línea?

Auditoría de ventas reales desde la línea de comandos

Asignatura: Ciencia de Datos en la Terminal Linux
Profesor: Luis Gómez
Nombre: Juan Pablo Vargas

22 de octubre de 2026

# ÍNDICE

01 Resumen ejecutivo

02 Fuente de datos y metodología

03 Auditoría y limpieza de los registros

04 Análisis exploratorio de ventas

05 Modelación predictiva por cliente

06 Hallazgos, conclusiones y recomendaciones

07 Reproducibilidad y referencias

# 1. Resumen ejecutivo

Se analizaron 541.909 registros del conjunto Online Retail. Tras aplicar criterios de exclusión documentados, quedaron 522.568 líneas válidas y 19.341 observaciones excluidas. El ingreso comercial válido alcanzó £10.247.905,13. El monto absoluto asociado a cancelaciones negativas fue £893.979,73, equivalente al 8,02% del bruto operativo definido en este análisis.

| Indicador | Resultado |
|---|---|
| Filas originales | 541.909 |
| Ventas comerciales válidas | 522.568 |
| Filas excluidas | 19.341 |
| Ingreso comercial válido | £10.247.905,13 |
| Cancelaciones negativas (valor absoluto) | £893.979,73 |

# 2. Fuente de datos y metodología

Fuente: Chen, D. (2015), Online Retail, UCI Machine Learning Repository. El conjunto contiene transacciones entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011.

El flujo se ejecutó desde una terminal Linux: descarga con curl, extracción con unzip, conversión desde Excel con in2csv, verificación con wc -l y csvstat, limpieza y agregados con scripts de Python invocados desde la terminal, y visualización con matplotlib.

Variables derivadas: Revenue = Quantity × UnitPrice; Month en formato AAAA-MM; Hour de 0 a 23. CustomerID se normalizó como entero e InvoiceDate conservó fecha y hora. Description se estandarizó en mayúsculas y con espacios simples. Los duplicados se detectaron antes de normalizar el texto.

# 3. Auditoría y limpieza de los registros

## 3.1. Valores faltantes en la fuente

| Columna | Faltantes | % del total |
|---|---|---|
| InvoiceNo | 0 | 0,00% |
| StockCode | 0 | 0,00% |
| Description | 1.454 | 0,27% |
| Quantity | 0 | 0,00% |
| InvoiceDate | 0 | 0,00% |
| UnitPrice | 0 | 0,00% |
| CustomerID | 135.080 | 24,93% |
| Country | 0 | 0,00% |

La ficha de UCI señala que CustomerID y Description pueden contener ausencias. Se mantienen las ventas con CustomerID vacío para medir ingresos, pero no entran al archivo de modelación por cliente: 131.418 ventas válidas sin identificador, por £1.510.677,49. La ausencia de Description motiva una exclusión conservadora cuando corresponda, para evitar rankings de productos no interpretables.

## 3.2. Anomalías detectadas (conteos independientes)

| Tipo de anomalía | Filas detectadas |
|---|---|
| Duplicados exactos | 5.268 |
| Facturas de cancelación (C) | 9.288 |
| Quantity no positiva o inválida | 10.624 |
| UnitPrice no positivo o inválido | 2.517 |
| Códigos especiales / no comerciales | 2.916 |
| Description faltante | 1.454 |
| CustomerID faltante | 135.080 |
| Quantity atípica (IQR) | 58.619 |
| UnitPrice atípico (IQR) | 39.627 |

Los conteos anteriores pueden superponerse. La regla de Tukey (Q1 − 1,5 × IQR; Q3 + 1,5 × IQR) arrojó límites de −12,50 a 23,50 para Quantity y de −3,07 a 8,45 para UnitPrice. No se eliminaron extremos automáticamente: el carácter mayorista de la tienda puede producir compras legítimas muy grandes.

## 3.3. Exclusión secuencial y rastreable

| Criterio prioritario | Excluidas | Restantes |
|---|---|---|
| Duplicado exacto | 5.268 | 536.641 |
| Cancelación | 9.251 | 527.390 |
| Cantidad inválida o no positiva | 1.336 | 526.054 |
| Precio inválido o no positivo | 1.176 | 524.878 |
| Código no comercial | 2.310 | 522.568 |
| Descripción faltante | 0 | 522.568 |
| Fecha inválida | 0 | 522.568 |

Cada fila excluida recibe un único motivo prioritario (ExclusionReason) en data/retail_anulaciones.csv. Se eliminaron las facturas C, cantidades y precios no positivos, duplicados exactos y códigos especiales POST, DOT, M, D, C2, BANK CHARGES, AMAZONFEE, S, B, CRUK y PADS. Este enfoque mide ingresos por productos comerciales y no necesariamente todos los movimientos contables de la empresa.

# 4. Análisis exploratorio de ventas

## 4.1. Distribuciones y valores extremos

| Variable | Media | Mediana | Mínimo | Máximo | Asimetría |
|---|---|---|---|---|---|
| Quantity | 10,64 | 4,00 | 1,00 | 80.995,00 | 468,82 |
| UnitPrice | 3,28 | 2,08 | 0,04 | 649,50 | 25,69 |
| Revenue | 19,61 | 9,90 | 0,06 | 168.469,60 | 515,96 |

Las tres distribuciones están fuertemente sesgadas a la derecha. Las medias superan las medianas por efecto de unas pocas líneas excepcionalmente grandes. Por ello, la mediana describe mejor la venta típica y los valores extremos deben interpretarse con cautela.

## 4.2. Ingresos, cancelaciones y diversidad comercial

| Indicador | Valor |
|---|---|
| Ingreso de ventas válidas | £10.247.905,13 |
| Cancelaciones negativas, valor absoluto | £893.979,73 |
| Bruto operativo utilizado | £11.141.884,86 |
| Tasa de cancelaciones | 8,02% |
| Facturas distintas | 19.773 |
| Clientes identificados | 4.334 |
| Productos distintos | 3.912 |

La cifra de cancelaciones no debe interpretarse automáticamente como pérdida financiera neta: algunas anulaciones pueden corresponder a ventas de otro período o a ajustes.

## 4.3. Productos con mayor ingreso

| Código | Producto | Ingreso (£) |
|---|---|---|
| 22423 | REGENCY CAKESTAND 3 TIER | 174.156,54 |
| 23843 | PAPER CRAFT, LITTLE BIRDIE | 168.469,60 |
| 85123A | CREAM HANGING HEART T-LIGHT HOLDER | 104.462,75 |
| 47566 | PARTY BUNTING | 99.445,23 |
| 85099B | JUMBO BAG RED RETROSPOT | 94.159,81 |
| 23166 | MEDIUM CERAMIC TOP STORAGE JAR | 81.700,92 |
| 23084 | RABBIT NIGHT LIGHT | 66.870,03 |
| 22086 | PAPER CHAIN KIT 50’S CHRISTMAS | 64.875,59 |
| 84879 | ASSORTED COLOUR BIRD ORNAMENT | 58.927,62 |
| 79321 | CHILLI LIGHTS | 54.096,36 |

### 4.4. Productos con más unidades vendidas

| Código | Producto | Unidades |
|---|---|---|
| 23843 | PAPER CRAFT, LITTLE BIRDIE | 80.995 |
| 23166 | MEDIUM CERAMIC TOP STORAGE JAR | 78.033 |
| 22197 | POPCORN HOLDER | 56.898 |
| 84077 | WORLD WAR 2 GLIDERS ASSTD DESIGNS | 54.951 |
| 85099B | JUMBO BAG RED RETROSPOT | 48.371 |
| 85123A | CREAM HANGING HEART T-LIGHT HOLDER | 37.641 |
| 21212 | PACK OF 72 RETROSPOT CAKE CASES | 36.396 |
| 84879 | ASSORTED COLOUR BIRD ORNAMENT | 36.362 |
| 23084 | RABBIT NIGHT LIGHT | 30.739 |
| 22492 | MINI PAINT SET VINTAGE | 26.633 |

Los rankings de ingreso y unidades comparten 6 de 10 productos. Por tanto, vender más unidades no siempre implica generar más ingresos, ya que los precios varían.

## 4.5. Concentración por país

| País | Ingresos (£) | Participación |
|---|---|---|
| United Kingdom | 8.725.129,48 | 85,14% |
| Netherlands | 283.889,34 | 2,77% |
| EIRE | 270.850,86 | 2,64% |
| Germany | 205.381,15 | 2,00% |
| France | 184.493,00 | 1,80% |
| Australia | 138.103,81 | 1,35% |
| Spain | 55.706,56 | 0,54% |
| Switzerland | 53.065,60 | 0,52% |
| Japan | 37.416,37 | 0,37% |
| Belgium | 36.927,34 | 0,36% |
| Otros 28 países / territorios | — | Resto |

El Reino Unido concentra 85,14% del ingreso válido. Esta dominancia debe tenerse presente al comparar mercados internacionales y al diseñar acciones comerciales. El PDF original contiene el desglose completo por país; aquí se destacan los principales para una lectura más limpia.

## 4.6. Ventas por mes y hora del día

| Mes | Ingresos (£) |
|---|---|
| 2010-12 | 775.714,95 |
| 2011-01 | 670.439,46 |
| 2011-02 | 507.866,54 |
| 2011-03 | 689.841,84 |
| 2011-04 | 515.469,66 |
| 2011-05 | 740.036,33 |
| 2011-06 | 737.683,99 |
| 2011-07 | 688.252,67 |
| 2011-08 | 724.308,16 |
| 2011-09 | 1.028.345,38 |
| 2011-10 | 1.103.330,92 |
| 2011-11 | 1.452.115,98 |
| 2011-12 | 614.499,25 |

El máximo mensual se registra en noviembre de 2011 (£1.452.115,98). Diciembre de 2011 comprende solo parte del mes, por lo que no debe compararse como un mes completo.

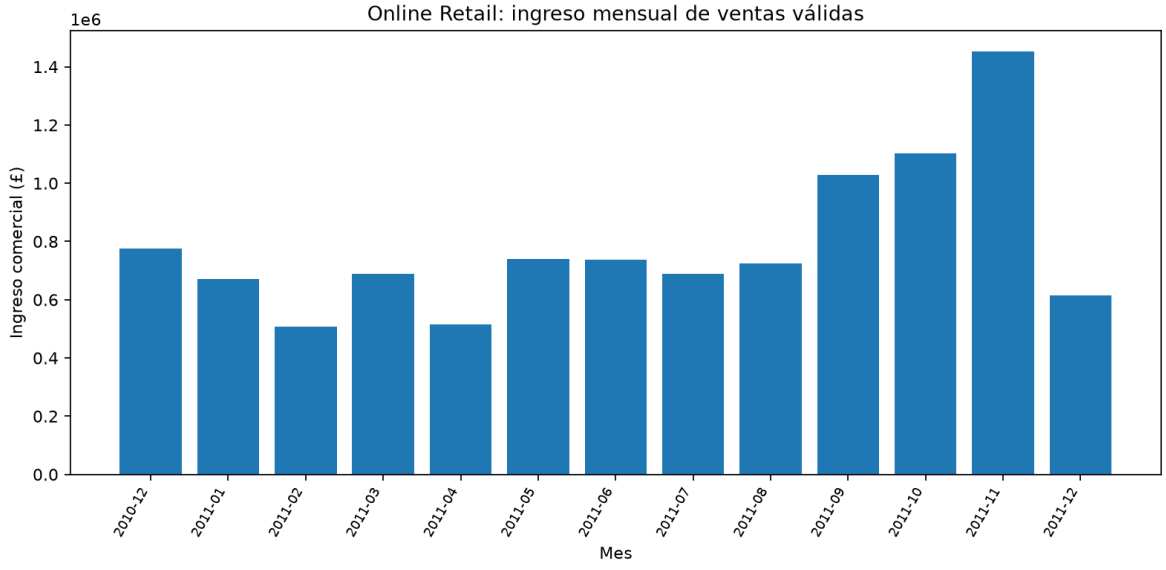



Figura 1. Ingreso mensual de ventas válidas (gráfico del informe original).

## Ingreso según la hora de la transacción

La actividad se concentra durante el horario comercial: a las 12:00 se registran £1.412.921,32 y a las 10:00, £1.401.791,40. El patrón se aprecia en la figura siguiente.

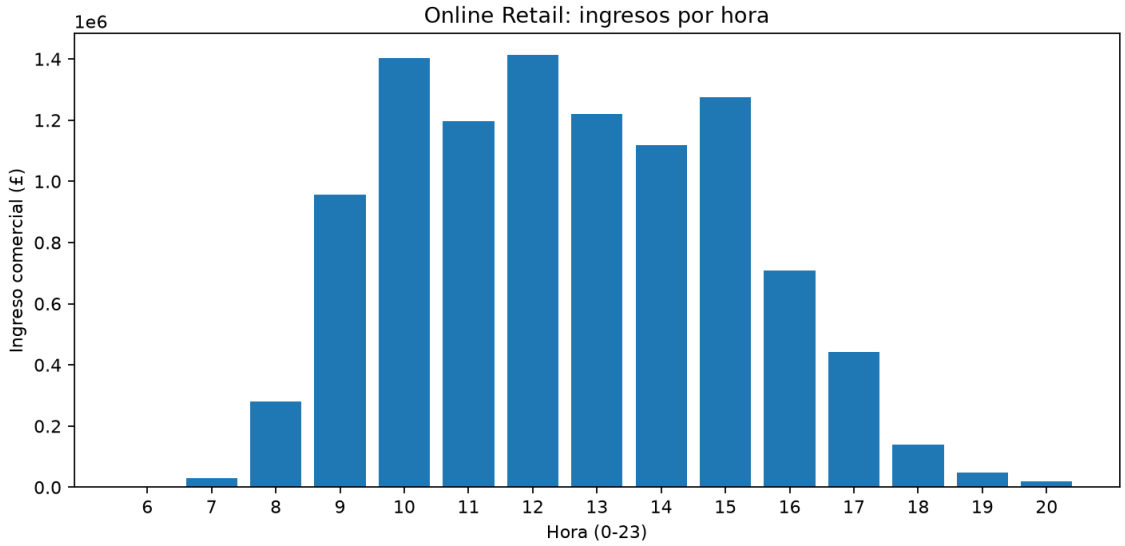



Figura 2. Ingresos por hora del día (gráfico del informe original).

## 4.7. Concentración de clientes y correlaciones

El ingreso por factura presenta mediana de £302,20, media de £518,28, cuartil inferior de £151,68, cuartil superior de £481,49 y máximo de £168.469,60. Los 10 clientes identificados con mayor gasto aportan 14,83% del ingreso comercial total, que incluye operaciones sin identificador en el denominador.

| | Quantity | UnitPrice | Revenue |
|---|---|---|---|
| Quantity | 1,0000 | −0,0221 | 0,9156 |
| UnitPrice | −0,0221 | 1,0000 | 0,0613 |
| Revenue | 0,9156 | 0,0613 | 1,0000 |

La correlación más fuerte se observa entre Quantity y Revenue (0,9156). Dado que Revenue es el producto de Quantity y UnitPrice, esta relación es aritmética, no causal; además, unos pocos valores extremos pueden dominar los coeficientes.

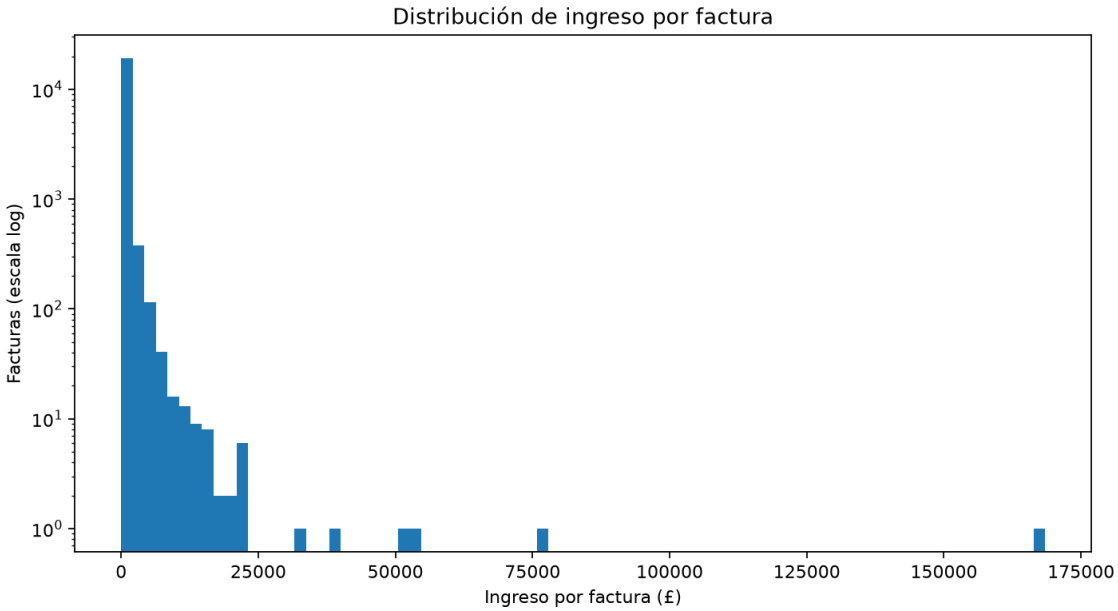



Figura 3. Distribución del ingreso por factura, en escala logarítmica para frecuencias (gráfico del informe original).

# 5. Modelación predictiva por cliente

Se agruparon 4.334 clientes identificados con las columnas exactas: CustomerID, Facturas, Productos, EsUK, MesPrimeraCompra e Ingreso. Facturas y Productos representan cantidades de identificadores distintos; EsUK indica si el país modal del cliente es Reino Unido; MesPrimeraCompra corresponde al mes de su primera transacción.

Con la partición reproducible solicitada (orden numérico, shuf --random-source=<(yes 42) y corte 70/30), se obtuvieron 3.033 observaciones de entrenamiento y 1.301 de prueba.

## 5.1. Comparación de modelos en la prueba

| Modelo | Objetivo | MAE (£) | $R^2$ |
|---|---|---|---|
| Base: media de entrenamiento | Original | 2.338,53 | −0,0002 |
| A: Facturas + Productos | Original | 1.464,32 | 0,3039 |
| A: Facturas + Productos | log(1+Ingreso) | 837.643.522,86 | $-8{,}11 \times 10^{12}$ |
| B: EsUK + MesPrimeraCompra | Original | 2.350,96 | 0,0074 |
| B: EsUK + MesPrimeraCompra | log(1+Ingreso) | 1.824,69 | −0,0161 |

## 5.2. Interpretación

Mejor modelo: el modelo A con objetivo original obtiene el menor MAE (£1.464,32) y el mayor $R^2$ de prueba (0,3039). Facturas y Productos recogen más información del volumen de actividad que el país y el mes de primera compra.

Clientes extremos: el 1% superior de clientes de prueba concentra 37,30% del ingreso de prueba. Esta concentración puede alterar considerablemente el $R^2$ y elevar el MAE.

Transformación logarítmica: el modelo A con log(1+Ingreso) tiene un error extraordinariamente grande al volver a escala monetaria. El comportamiento es compatible con predicciones extremas amplificadas por la transformación exponencial, aunque no se verificaron individualmente esas predicciones. Se conserva el resultado tal como fue calculado; no se modifica manualmente.

Limitaciones: el modelo B ofrece poca capacidad predictiva. Además, usar facturas y productos medidos durante el mismo período que el ingreso convierte el ejercicio principalmente en una asociación explicativa, no en un pronóstico futuro sin fuga de información. Un solo $R^2$ de prueba es frágil ante muestras con pocos clientes muy grandes; sería conveniente repetir particiones o aplicar validación cruzada.

# 6. Hallazgos, conclusiones y recomendaciones

• Concentración geográfica: United Kingdom concentra el 85,14% del ingreso válido.

• Cancelaciones: £893.979,73 aparecen asociados a cancelaciones negativas (8,02% del bruto operativo definido); no equivalen automáticamente a pérdida neta.

• Concentración comercial: los 10 clientes identificados más importantes aportan el 14,83% del ingreso comercial registrado.

Recomendación: monitorear mensualmente las cancelaciones, la facturación por producto y la concentración de compradores; separar ventas de artículos y operaciones administrativas. Para un eventual sistema de pronóstico, definir predictores de períodos anteriores al ingreso objetivo, repetir la validación y prestar especial atención a los clientes de gasto elevado.

# 7. Reproducibilidad y referencias

El flujo se ejecuta en Ubuntu desde la raíz del proyecto con bash scripts/pipeline.sh. El script descarga los datos de UCI y genera los archivos de limpieza, las particiones, las métricas y el reporte. El entorno inicial requiere python3, python3-venv, python3-pip, curl y unzip, más las dependencias especificadas en requirements.txt.

Archivos principales: data/retail_clean.csv, data/retail_anulaciones.csv, data/clientes.csv, data/train.csv, data/test.csv, report/modelos.json, report/resultados.json, report/factura.txt y report/reporte.md.

Referencia: Chen, D. (2015). Online Retail. UCI Machine Learning Repository. https://doi.org/10.24432/C5BW33.

Nota editorial: Esta versión reorganiza la presentación del informe ejecutado y conserva sus cifras. Los resultados deben comprobarse con los archivos generados por el pipeline si se modifica el procedimiento de análisis.